

# Ideazione di una pipeline OCR locale per estrarre dati da documenti di trasporto

Matteo Mazzaretto

14 Luglio 2026



# SPAZIO DEV Problema

## Estrarre dati da fonti semi-strutturate

[illegible]

# Attualità

## Sistema basato su LLM/API esterne a pagamento

## Soluzione

# Pipeline di OCR locale basata su soluzioni algoritmiche

## Benefici

Soluzione deterministica,  
abbattimento dei costi  
operativi



## DocTR - Document Text Recognition

Basata su transformer  
e reti neurali  
convoluzionali

Progettata per il  
riconoscimento di  
testo nei documenti

Rilevamento righe,  
parole e coordinate



## Funzionali

- Indicatori di affidabilità dei risultati
- Supporto a template DDT multipli
- Gestione di rotazione, contrasto e rumore dei PDF

## Di vincolo

- Pipeline OCR completamente locale
- Distribuzione tramite Docker
- Gestione di PDF multipagina

1. Estrarre con OCR il testo;
2. Ricavare i dati con regular expression.


| <b>Numero colli</b> | 1     |
|---------------------|-------|
| <b>Peso lordo</b>   | 1.0KG |

| <b>Numero colli</b> | <b>Peso lordo</b> |
|---------------------|-------------------|
| 1                   | 1.0KG             |

Problema: le RegExp non hanno conoscenza spaziale del testo.


- Costruzione del template
- Gestire l'inclinazione dei DDT e la loro rotazione
- Gestire i fornitori con diversi template
- Gestire l'estrazione degli articoli

## Estrazione di un DDT



The screenshot shows the 'Estrai dati DDT' (Extract DDT data) interface. At the top, there are three tabs: 'REDOX OCR', 'Estrai DDT' (which is active), and 'Editor template'. Below the tabs, the title 'Estrai dati DDT' is displayed. Underneath, there is a section labeled 'File PDF' with a dashed box containing the text 'Trascina un PDF qui o clicca per selezionarlo'. Below this, there is a 'Template fornitore' (Supplier template) section with a dropdown menu currently showing 'Seleziona'. At the bottom right of this section is a blue button labeled 'Estrai dati'.

## Creazione di un template



The screenshot shows the 'Editor template' interface. At the top, there are three tabs: 'REDOX OCR', 'Estrai DDT', and 'Editor template' (which is active). Below the tabs, there is a 'Carica PDF' button and a 'Template' dropdown menu. To the right of the dropdown menu, there is a 'Fornitore' (Supplier) dropdown menu, a 'Nome Fornitore' input field, and an 'Ancora pagina chiara' checkbox. Below these, there is a 'Riepilogo' section with a 'Totale: Totale' label and a 'Ignora right' checkbox. At the bottom right of this section is a blue button labeled 'Salva Template'. Below the 'Riepilogo' section, there is a large white rectangular area for editing the template.



# Costruzione del template



| Cod. Articolo                                                                   | Descrizione                                                                         | Data Richiesta | U.M. | Quantità |
|---------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|----------------|------|----------|
| 38316.005.003                                                                   | VITE VAVI00299- OTTONE S/P ORO 22 AA 0,5 Minimo + GR7-<br>Applicazione frenafiletto |                | PZ   | 4.800,00 |
| PRODOTTO DA USARE: 3M SCOTCH GRIP 2353 RESINA EPOSSIDICA<br>DI COLORE BLU SCURO |                                                                                     |                |      |          |

# Deskewing



UNIVERSITÀ  
DI PADOVA

| CODICE ARTICOLO      | DESCRIZIONE                                  | UM | QUANTITA'  |
|----------------------|----------------------------------------------|----|------------|
| VITE 3X6 TB.8 AMDLR  | VITE Ø 3X6 TB. 8 AMDL A ROTO                 | PZ | • 3.000,00 |
| VITE 2X3 P006-07R    | VITE Ø 2X3 P006-07 A ROTO                    | PZ | • 1.600,00 |
| VI 2.6X4T3.5 OVERS1R | VITE 2.6X4 T. 3.5 OVERS1 A ROTO              | PZ | • 2.500,00 |
| VITE 3X3 T.4 NKPA1R  | VITE Ø 3X3 T. 4 NKPA1 A ROTO                 | PZ | • 4.400,00 |
| VI 2.6X6 T3.5 NKPA1R | VITE Ø 2,6X6 T. 3,5 NKPA1 A ROTO             | PZ | • 2.200,00 |
| VITE 2X4             | VITE Ø 2X4 GREZZA                            | PZ | • 1.000,00 |
| VITE 2.6X4.5 ROTO    | VITE Ø 2,6X4,5 GREZZA                        | PZ | • 1.000,00 |
| VITE 2X5 TORX INOX   | VITE Ø 2X5 TORX INOX                         | PZ | • 5.000,00 |
| GRANO INOX 2X4 G100R | GRANO INOX Ø 2X4 ORO STRIKE 0.05 + G100 ROTO | PZ | • 7.000,00 |
| VITE 2X3 G022-04R    | VITE Ø 2X3 G022-04 A ROTO                    | PZ | • 2.600,00 |
|                      | **METTERE BLOCCAFIETTI**                     |    |            |
|                      | ***MERCE IN ORDINE PER CONTO DI TOD'S SPA*** |    |            |

| CODICE ARTICOLO      | DESCRIZIONE                                  | UM | QUANTITA'  |
|----------------------|----------------------------------------------|----|------------|
| VITE 3X6 TB.8 AMDLR  | VITE Ø 3X6 TB. 8 AMDL A ROTO                 | PZ | • 3.000,00 |
| VITE 2X3 P006-07R    | VITE Ø 2X3 P006-07 A ROTO                    | PZ | • 1.600,00 |
| VI 2.6X4T3.5 OVERS1R | VITE 2.6X4 T. 3.5 OVERS1 A ROTO              | PZ | • 2.500,00 |
| VITE 3X3 T.4 NKPA1R  | VITE Ø 3X3 T. 4 NKPA1 A ROTO                 | PZ | • 4.400,00 |
| VI 2.6X6 T3.5 NKPA1R | VITE Ø 2,6X6 T. 3,5 NKPA1 A ROTO             | PZ | • 2.200,00 |
| VITE 2X4             | VITE Ø 2X4 GREZZA                            | PZ | • 1.000,00 |
| VITE 2.6X4.5 ROTO    | VITE Ø 2,6X4,5 GREZZA                        | PZ | • 1.000,00 |
| VITE 2X5 TORX INOX   | VITE Ø 2X5 TORX INOX                         | PZ | • 5.000,00 |
| GRANO INOX 2X4 G100R | GRANO INOX Ø 2X4 ORO STRIKE 0.05 + G100 ROTO | PZ | • 7.000,00 |
| VITE 2X3 G022-04R    | VITE Ø 2X3 G022-04 A ROTO                    | PZ | • 2.600,00 |
|                      | **METTERE BLOCCAFIETTI**                     |    |            |
|                      | ***MERCE IN ORDINE PER CONTO DI TOD'S SPA*** |    |            |

# Gestire i fornitori con diversi template




```
function select_best_template(variants, words):  
    if variants has one element:  
        return load(variants[0], words)  
  
    best = none  
    for variant in variants:  
        anchor = variant.anchor  
        expected = anchor.center()  
        found = variant.find_anchor(words)  
        if found is none:  
            continue  
        distance = expected.distance_to(found)  
        if distance < best.distance:  
            best = variant  
  
    if best is none:  
        return none  
  
    best.apply_anchor_offset(words)  
    return best
```

## Estrazione delle parole nel rettangolo

```
function words_in_rect(bounding_box, words):  
    found = []  
    for word in words:  
        if not word.overlaps(bounding_box):  
            continue  
        if word.overlap_size(bounding_box).x >= OVERLAP_RATIO:  
            found.append(word)  
    return found
```

## Raggruppamento articoli per quantità

```
function group_lines_by_quantity(lines, quantity_box):  
    groups = []  
    current = none  
    for line in lines:  
        if line.has_summary_keyword():  
            break  
        if line.has_quantity(quantity_box):  
            if current != none:  
                groups.append(current)  
                current = new_group(line)  
        else:  
            current.extend(line)  
    groups.append(current)  
    return groups
```



| Tipo       | Obb     | Des | Opz |
|------------|---------|-----|-----|
| Funzionale | 146/146 | 1/1 | 4/4 |
| Qualità    | 1/1     | 0/0 | 0/0 |
| Vincolo    | 4/4     | 0/0 | 2/2 |

Testando l'algoritmo su tutti i DDT di esempio disponibili, il numero di articoli estratti risulta corretto nel **99,04%** dei casi.

Questo dato non garantisce però che ogni singolo campo sia esatto: da un controllo manuale a campione, stimo l'affidabilità reale più vicina all'**80-90%**.

Grazie per l'attenzione!